

EAE1106 - Métodos Computacionais para Economia

Danilo Souza

Índice

Bem-vindo	4
Agradecimentos e reprodução	4
Alfabetização computacional e lógica básica	5
I alfabetizacao.qmd	6
1 Fundamentos de computação	7
2 Primeiros passos no Python	8
3 Programação e IA	9
4 Tipos primitivos e objetos básicos	10
5 Controle de fluxo e iteração	11
6 Funções	12
II Computação numérica, análise de dados e visualização	13
7 Arrays, matrizes e álgebra linear	15
7.1 O que é o NumPy?	15
7.2 Elementos básicos do NumPy	16
7.2.1 Arrays unidimensionais	16
7.2.2 Arrays multidimensionais	18
7.2.3 Propriedades de arrays	19
7.3 Operações básicas com arrays	21
7.3.1 Operações aritméticas simples	21
7.3.2 Funções universais	26
7.3.3 Arrays e listas	28
7.4 Aplicação: solução de sistema de equações lineares	29
7.4.1 Algoritmo de eliminação de Gauss-Jordan	29
7.4.2 Solução de sistemas exatamente identificados	33

8	Gestão e análise de dados	36
8.1	O que é o NumPy?	36
9	Visualização	37
9.1	O que é o NumPy?	37
10	Análise empírica integrada	38
10.1	O que é o NumPy?	38
III	Temas complementares	39
11	Introdução à programação orientada a objetos (OOP)	40
12	Introdução ao R	41
	References	42

Bem-vindo

Este é o material da disciplina **EAE1106 — Métodos Computacionais para Economia**, ministrada no Departamento de Economia da USP.

O curso tem como objetivo introduzir lógica de programação e análise de dados utilizando principalmente **Python**, com uma breve introdução a **R** ao final do semestre.

Agradecimentos e reprodução

Esse material deve muito a X, Y e Z

Esse material foi construído bla bla bla. Qualquer erro é de responsabilidade exclusiva do autor. Todo e qualquer feedback é muito bem-vindo.

Alfabetização computacional e lógica básica

Este é o material da disciplina **EAE1106 — Métodos Computacionais para Economia**, ministrada no Departamento de Economia da USP.

O curso tem como objetivo introduzir lógica de programação e análise de dados utilizando principalmente **Python**, com uma breve introdução a **R** ao final do semestre.

Parte I

alfabetizacao.qmd

1 Fundamentos de computação

In summary, this book has no content whatsoever.

2 Primeiros passos no Python

In summary, this book has no content whatsoever.

3 Programação e IA

In summary, this book has no content whatsoever.

4 Tipos primitivos e objetos básicos

In summary, this book has no content whatsoever.

5 Controle de fluxo e iteração

In summary, this book has no content whatsoever.

6 Funções

In summary, this book has no content whatsoever.

Parte II

Computação numérica, análise de dados e visualização

Este é o material da disciplina **EAE1106 — Métodos Computacionais para Economia**, ministrada no Departamento de Economia da USP.

O curso tem como objetivo introduzir lógica de programação e análise de dados utilizando principalmente **Python**, com uma breve introdução a **R** ao final do semestre.

7 Arrays, matrizes e álgebra linear

Uma das principais aplicações para o Python bla bla bla

7.1 O que é o NumPy?

NumPy (**N**umerical **P**ython) é o pacote fundamental para computação científica em Python. Essa biblioteca é peça fundamental em outras bibliotecas igualmente importantes, como o Pandas e o Matplotlib. É uma biblioteca Python que tem como principal objeto o `ndarray`, um array multidimensional que guarda bastante semelhança com a ideia de vetores e matrizes, embora seja um objeto específico dentro da linguagem, com suas características e métodos próprios. O pacote contém também uma variedade de rotinas para operações rápidas em arrays, incluindo matemática, lógica, álgebra linear básica, operações estatísticas básicas e muito mais.

Mas o que é de fato um `ndarray`? É um objeto multidimensional que nos permite armazenar dados de forma sequencial e que podem ser acessados via indexação. Ué, mas isso é muito parecido com uma lista (ou um conjunto de listas). Qual a diferença então?

- NumPy arrays têm um tamanho fixo na criação, ao contrário das listas, que podem crescer. Alterar o tamanho de um `ndarray` criará um novo array e excluirá o original.
- Todos os elementos em um array devem ser do mesmo tipo de dados, diferentemente de listas, que são objetos mais genéricos. Isso facilita a gestão de memória e torna operações com esse tipo de objeto ordens de magnitude mais rápidas do que se utilizássemos listas.
- A maior velocidade e eficiência de armazenamento fazem do NumPy uma das bibliotecas mais utilizadas em aplicações matemáticas e científicas. Saber apenas as ferramentas nativas do Python, como listas, hoje já não é mais suficiente.

São muitas as qualidades do NumPy que fazem dele a melhor escolha quanto o assunto é lidar com objetos sequenciais, multidimensionais, e com os quais queremos operar tal qual vetores e matrizes. Mas chega de lenga lenga, vamos ao trabalho!

7.2 Elementos básicos do NumPy

Antes de tudo, é preciso importar o NumPy, já que se trata de uma biblioteca não nativa do Python.

```
import numpy as np
```

7.2.1 Arrays unidimensionais

Começamos criando um `numpy.ndarray` do zero, contendo os números 1, 2 e 3. Podemos fazê-lo da seguinte forma:

```
a = np.array([1, 2, 3])
print(a)
print(type(a))
```

```
[1 2 3]
<class 'numpy.ndarray'>
```

A sintaxe é essa mesma: um par de colchetes dentro dos parênteses. Se tentarmos passar sem os colchetes, o Python retornará um erro.

```
a = np.array(1, 2, 3)
```

```
TypeError: array() takes from 1 to 2 positional arguments but 3 were given
```

```
-----
TypeError                                Traceback (most recent call last)
Cell In[3], line 1
----> 1 a = np.array(1, 2, 3)
TypeError: array() takes from 1 to 2 positional arguments but 3 were given
```

Da mesma forma que uma sequência de 3 números inteiros, podemos criar um `numpy.ndarray` que repete 3 vezes o número 0 ou 3 vezes o número 1.

```
a = np.zeros(3)
b = np.ones(3)

print(a)
print(b)
```



```
[0. 0. 0.]
[1. 1. 1.]
```

Note que em ambos os casos os números aparecem com o ponto da casa decimal, o que é um indicativo de que estão armazenados como valores do tipo `float`. E se quiséssemos criar esses mesmos arrays, mas especificando que os números são inteiros, i.e., do tipo `int`?

```
a = np.zeros(3, dtype=int)
b = np.ones(3, dtype=int)

print(a)
print(b)
```

```
[0 0 0]
[1 1 1]
```

A função `numpy.linspace(x,y,z)` nos permite criar um array que vai de `x` até `y`, com `z` elementos igualmente espaçados.

```
a = np.linspace(0,8,5, dtype=int)

print(a)
```

```
[0 2 4 6 8]
```

Podemos acessar os elementos de um array qualquer utilizando a mesma ideia de indexação de listas:

```
print('Array a =',a)
print('\nPrimeiro elemento de a = ',a[0])
print('Segundo elemento de a = ',a[1])
print('Último elemento de a = ',a[-1])
print('Dois primeiros elementos de a = ',a[0:2])
```

```
Array a = [0 2 4 6 8]
```

```
Primeiro elemento de a = 0
Segundo elemento de a = 2
Último elemento de a = 8
Dois primeiros elementos de a = [0 2]
```

7.2.2 Arrays multidimensionais

Como falamos anteriormente, um objeto do tipo `numpy.ndarray` é um array *n-dimensional* (por isso o **nd** em **ndarray**). Até agora trabalhamos apenas com uma dimensão, mas para as nossas aplicações é particularmente interessante o caso em que o número de dimensões é igual a 2, i.e., para o caso em que o array assume a forma de uma **matriz**.

Podemos criar esse tipo de array usando a mesma lógica de antes, com pequenas alterações na sintaxe:

```
A_22 = np.array([[1, 2], [3, 4]], dtype=int)

print('Matriz A =\n',A_22)
```

```
Matriz A =
[[1 2]
 [3 4]]
```

O NumPy nos oferece algumas funções interessantes para criarmos matrizes específicas:

```
print('Matriz identidade 2x2 =\n',np.eye(2,dtype=int))
print('\nMatriz diagonal 3x3 =\n',np.diag([1,2,3]))
```

```
Matriz identidade 2x2 =
[[1 0]
 [0 1]]
```

```
Matriz diagonal 3x3 =
[[1 0 0]
 [0 2 0]
 [0 0 3]]
```

Podemos criar a matriz **transposta** de uma dada matriz utilizando a função `np.transpose()` (ou apenas o método `.T`):

```
print('Matriz A =\n',A_22)
print('\nTransposta da matriz A =\n',np.transpose(A_22))
print('\nTransposta da matriz A =\n',A_22.T)
```

```
Matriz A =  
[[1 2]  
 [3 4]]
```

```
Transposta da matriz A =  
[[1 3]  
 [2 4]]
```

```
Transposta da matriz A =  
[[1 3]  
 [2 4]]
```

Assim como em arrays unidimensionais, podemos acessar os elementos de uma matriz utilizando indexação, mas agora em 2 dimensões:

```
A = np.array([[1,2,3], [4,5,6], [7,8,9]])  
  
print('Matriz A =\n',A)  
print('\nElemento 11 de A = ',A[0,0])  
print('Elemento 23 de A = ',A[1,2])  
print('Primeira linha de A = ',A[0,:])  
print('Segunda coluna de A = ',A[:,1])  
print('\nSubmatriz de A delimitada pelos elementos 22 e 33 =\n',A[1:,1:])
```

```
Matriz A =  
[[1 2 3]  
 [4 5 6]  
 [7 8 9]]
```

```
Elemento 11 de A = 1  
Elemento 23 de A = 6  
Primeira linha de A = [1 2 3]  
Segunda coluna de A = [2 5 8]
```

```
Submatriz de A delimitada pelos elementos 22 e 33 =  
[[5 6]  
 [8 9]]
```

7.2.3 Propriedades de arrays

O NumPy fornece alguns métodos úteis que, apesar de não receberem nenhum argumento, nos permitem acessar algumas das características dos arrays que criamos.

- `ndim` retorna o número de dimensões do array;
- `shape` retorna o tamanho do array em cada uma de suas dimensões;
- `dtype` retorna o tipo de dado contido no array;
- `size` retorna o número total de elementos contidos no array.

```
X1 = np.array([[1,2,3], [4,5,6], [7,8,9]])
X2 = X1.flatten() # O método flatten reduz um array de n-dimensões em um array de uma única d

print('Array X1 =\n',X1)
print('\nDimensões de X1 = ', X1.ndim)
print('Shape de X1 = ', X1.shape)
print('Tipo de dado em X1 = ', X1.dtype)
print('Número de elementos em X1 = ', X1.size)

print('\n\nArray X2 =\n',X2)
print('\nDimensões de X2 = ', X2.ndim)
print('Shape de X2 = ', X2.shape)
print('Tipo de dado em X2 = ', X2.dtype)
print('Número de elementos em X2 = ', X2.size)
```

```
Array X1 =
[[1 2 3]
 [4 5 6]
 [7 8 9]]
```

```
Dimensões de X1 = 2
Shape de X1 = (3, 3)
Tipo de dado em X1 = int64
Número de elementos em X1 = 9
```

```
Array X2 =
[1 2 3 4 5 6 7 8 9]
```

```
Dimensões de X2 = 1
Shape de X2 = (9,)
Tipo de dado em X2 = int64
Número de elementos em X2 = 9
```

Um método interessante de arrays é o `reshape(x,y)` que reorganiza um array existente de acordo com os argumentos `x` e `y`:

```
X = np.array([[1,2,3,4], [5,6,7,8], [9,10,11,12], [13,14,15,16]])

print('Array X1 4x4 =\n',X)
print('\n X1 reorganizado em 2x8 =\n',X.reshape(2,8))
print('\n X1 reorganizado em 8x2 =\n',X.reshape(8,2))
```

```
Array X1 4x4 =
[[ 1  2  3  4]
 [ 5  6  7  8]
 [ 9 10 11 12]
 [13 14 15 16]]
```

```
X1 reorganizado em 2x8 =
[[ 1  2  3  4  5  6  7  8]
 [ 9 10 11 12 13 14 15 16]]
```

```
X1 reorganizado em 8x2 =
[[ 1  2]
 [ 3  4]
 [ 5  6]
 [ 7  8]
 [ 9 10]
 [11 12]
 [13 14]
 [15 16]]
```

7.3 Operações básicas com arrays

7.3.1 Operações aritméticas simples

Dois tipos de operações que serão úteis para arrays de qualquer dimensão são:

1. Operações entre um array e um único número.
2. Operações entre dois arrays da mesma forma.

Quando realizamos operações em um array usando um único número, simplesmente aplicamos essa operação a cada elemento do array. Isso vale tanto para arrays unidimensionais (vetores) quanto multidimensionais (por ex., matrizes).

```
x = np.array([1,2,3], dtype=int)
print("x =\n", x)
print("\n2 + x =\n", 2 + x)
print("\n2 - x =\n", 2 - x)
print("\n2 * x =\n", 2 * x)
print("\nx / 2 =\n", x / 2)
```

```
x =
[1 2 3]
```

```
2 + x =
[3 4 5]
```

```
2 - x =
[ 1  0 -1]
```

```
2 * x =
[2 4 6]
```

```
x / 2 =
[0.5 1.  1.5]
```

```
X = np.ones((2, 2), dtype=int)

print("X =\n", X)
print("\n2 + X =\n", 2 + X)
print("\n2 - X =\n", 2 - X)
print("\n2 * X =\n", 2 * X)
print("\nX / 2 =\n", X / 2)
```

```
X =
[[1 1]
 [1 1]]
```

```
2 + X =
[[3 3]
 [3 3]]
```

```
2 - X =
[[1 1]
 [1 1]]
```

```
2 * X =  
[[2 2]  
 [2 2]]
```

```
X / 2 =  
[[0.5 0.5]  
 [0.5 0.5]]
```

Para operações entre dois arrays de mesmo tamanho, basta aplicar a operação elemento a elemento (*elementwise*, em inglês) entre os arrays.

```
x = np.array([2, 4, 6], dtype=int)  
y = np.array([2, 2, 1], dtype=int)  
  
print("x =\n", x)  
print("\ny =\n", y)  
print("\nx + y =\n", x + y)  
print("\nx - y =\n", x - y)
```

```
x =  
[2 4 6]
```

```
y =  
[2 2 1]
```

```
x + y =  
[4 6 7]
```

```
x - y =  
[0 2 5]
```

```
X = np.array([[2, 4], [6, 8]], dtype=int)  
Y = np.array([[2, 2], [2, 2]], dtype=int)  
  
print("X =\n", X)  
print("\nY =\n", Y)  
print("\nX + Y =\n", X + Y)  
print("\nX - Y =\n", X - Y)
```

```
X =
```

```
[[2 4]
 [6 8]]
```

```
Y =
[[2 2]
 [2 2]]
```

```
X + Y =
[[ 4  6]
 [ 8 10]]
```

```
X - Y =
[[0 2]
 [4 6]]
```

As operações de multiplicação e divisão entre arrays são um pouco diferentes. São duas as possibilidades:

- Multiplicação e divisão elemento a elemento.
- Multiplicação entre arrays usando a lógica de matriz e “divisão” usando a lógica de matriz inversa.

Para realizar as operações *elementwise* basta utilizar os sinais usuais de `*` e `/`, independentemente do número de dimensões do array.

```
print('Vetores x e y:')
print('x =',x)
print('y =',y)
print("\n x * y =\n", x * y)
print("\n x / y =\n", x / y)

print('\nMatrizes X e Y:')
print('X =\n',X)
print('Y =\n',Y)
print("\n X * Y =\n", X * Y)
print("\n X / Y =\n", X / Y)
```

```
Vetores x e y:
x = [2 4 6]
y = [2 2 1]
```

```
x * y =
```



```
[4 8 6]
```

```
x / y =  
[1. 2. 6.]
```

Matrizes X e Y:

```
X =  
[[2 4]  
 [6 8]]
```

```
Y =  
[[2 2]  
 [2 2]]
```

```
X * Y =  
[[ 4  8]  
 [12 16]]
```

```
X / Y =  
[[1. 2.]  
 [3. 4.]]
```

A **multiplicação** de matriz com matriz, do jeito que a gente conhece do Ensino Médio é feita usando o símbolo @ (ou através da função `np.dot()`):

```
X= np.array([[1, 2], [3, 4]], dtype=int)  
Y= np.array([[10, 20], [30, 40]], dtype=int)  
  
print('X =\n',X)  
print('Y =\n',Y)  
print('\nX * Y =\n', X @ Y)  
print('\nX * Y =\n', np.dot(X,Y))
```

```
X =  
[[1 2]  
 [3 4]]  
Y =  
[[10 20]  
 [30 40]]
```

```
X * Y =  
[[ 70 100]  
 [150 220]]
```

```
X * Y =  
[[ 70 100]  
 [150 220]]
```

Para calcular a inversa de uma matriz utilizando o NumPy é preciso um pouco mais de estrutura e de conhecimento acerca do subpacote `linalg` que nos traz funções para realizar operações de álgebra linear. Falaremos disso já já!

7.3.2 Funções universais

As funções universais no Numpy são funções matemáticas simples. É apenas um termo que demos às funções matemáticas na biblioteca Numpy, que cobrem uma ampla variedade de operações. Essas funções incluem funções trigonométricas padrão, funções para operações aritméticas, manipulação de números complexos, funções estatísticas, etc. Essas funções possuem como características principais:

- Elas executam operações de array elemento por elemento.
- Elas suportam vários recursos, como conversão de tipos.
- As funções universais são objetos que pertencem à classe `numpy.ufunc`.
- As funções do Python também podem ser criadas como uma função universal usando a função da biblioteca `frompyfunc`.
- Algumas funções universais são chamadas automaticamente quando o operador aritmético correspondente é usado em arrays. Por exemplo, quando a adição de dois arrays é executada em elementos usando o operador '+', então `np.add()` é chamado internamente.

Dentre as principais funções universais matemáticas estão:

- `sin`, `cos`, `tan`: calcular seno, cosseno e tangente de ângulos.
- `hypot`: calcule a hipotenusa do triângulo retângulo dado.
- `arcsinh`, `arcosh`, `arctanh`: calcular seno hiperbólico inverso, cosseno e tangente.
- `deg2rad`: converter grau em radianos.
- `rad2deg`: converter radianos em graus.

Dentre as principais funções universais estatísticas estão:

- `amin`, `amax`: retorna o mínimo ou máximo de um array ou ao longo de um eixo.
- `ptp`: retorna o intervalo de valores (máximo-mínimo) de um array ou ao longo de um eixo.
- `sum`: retorna a soma de valores de um array ao longo de um eixo.
- `percentile(a, p, eixo)`: calcular o p-ésimo percentil da matriz ou ao longo do eixo especificado.
- `median`: calcular a mediana dos dados ao longo do eixo especificado.

- **mean**: calcular a média dos dados ao longo do eixo especificado.
- **var**: calcular a variância de dados ao longo do eixo especificado.
- **log**: calcular o log dos dados ao longo do eixo especificado.

Alguns exemplos:

```
angulos_notaveis_deg = np.array([30,45,60])
angulos_notaveis_rad = np.deg2rad(angulos_notaveis_deg)

seno_notaveis = [np.round(elem,2) for elem in np.sin(angulos_notaveis_rad)]
cosseno_notaveis = [np.round(elem,2) for elem in np.cos(angulos_notaveis_rad)]
tangente_notaveis = [np.round(elem,2) for elem in np.tan(angulos_notaveis_rad)]

print('Seno, cosseno e tangente de 30 graus: ', seno_notaveis[0], ', ', cosseno_notaveis[0], ' e '
print('Seno, cosseno e tangente de 45 graus: ', seno_notaveis[1], ', ', cosseno_notaveis[1], ' e '
print('Seno, cosseno e tangente de 60 graus: ', seno_notaveis[2], ', ', cosseno_notaveis[2], ' e ')
```

```
Seno, cosseno e tangente de 30 graus:  0.5 ,  0.87 e  0.58
Seno, cosseno e tangente de 45 graus:  0.71 ,  0.71 e  1.0
Seno, cosseno e tangente de 60 graus:  0.87 ,  0.5 e  1.73
```

```
x = np.array([1,2,3,4,5])

print('Array x = ',x)
print('\nMínimo de x = ',np.amin(x))
print('Máximo de x = ',np.amax(x))
print('Intervalo de x = ',np.ptp(x))
print('Soma de x = ',np.sum(x))
print('Média de x = ',np.mean(x))
print('Log de x = ',[np.round(elem,2) for elem in np.log(x)])
```

```
Array x =  [1 2 3 4 5]
```

```
Mínimo de x =  1
Máximo de x =  5
Intervalo de x =  4
Soma de x =  15
Média de x =  3.0
Log de x =  [np.float64(0.0), np.float64(0.69), np.float64(1.1), np.float64(1.39), np.float64(1.61)]
```

7.3.3 Arrays e listas

Agora que já vimos um pouco de operações básicas, podemos entender um pouco melhor a diferença de desempenho entre arrays e listas. Considere um array de dez milhões de números inteiros e uma lista equivalente:

```
my_array = np.arange(10000000)
my_list = list(range(10000000))
```

Agora vamos multiplicar, elemento a elemento, todos os números por 2 e salvar o resultado correspondente. Utilizaremos a função `time` do pacote `time` para fazer a medição do tempo utilizado pelos dois métodos.

```
import time

# arrays
start_array = time.time()
my_array2 = my_array * 2
end_array = time.time()

# listas
start_list = time.time()
my_list2 = [x * 2 for x in my_list]
end_list = time.time()

ratio = (end_list - start_list) / (end_array - start_array)
```

Qual abordagem será que levou menos tempo?

```
print('Tempo necessário para a realização dos cálculos utilizando arrays: {:.4f} segundos'.format(end_array - start_array))
print('Tempo necessário para a realização dos cálculos utilizando listas: {:.4f} segundos'.format(end_list - start_list))
print('\nA abordagem de listas demorou {:.0f}x mais tempo! Esqueça listas e use arrays ;)'.format(ratio))
```

```
Tempo necessário para a realização dos cálculos utilizando arrays: 0.0139 segundos
Tempo necessário para a realização dos cálculos utilizando listas: 0.2834 segundos
```

```
A abordagem de listas demorou 19x mais tempo! Esqueça listas e use arrays ;)
```

7.4 Aplicação: solução de sistema de equações lineares

Chega de exemplos vazios, vamos usar o NumPy para resolver um problema concreto e que nos é muito familiar: a solução de sistemas de equações lineares. Considere o sistema linear de equações dado por

$$A \cdot \vec{x} = \vec{b}$$

tal que A é a matriz de coeficientes, \vec{x} é o vetor de incógnitas e \vec{b} o vetor de constantes.

7.4.1 Algoritmo de eliminação de Gauss-Jordan

Segundo [Hubbard e Hubbard \(2015\)](#), uma matriz de coeficientes A é representada em sua forma escalonada reduzida por linhas (*reduced row echelon form*, em inglês) se

- Em toda e qualquer linha, a primeira entrada diferente de zero é igual a 1 (1 *pivotal*).
- O 1 *pivotal* de uma linha mais abaixo está sempre à direita de um outro 1 *pivotal* de alguma linha acima.
- Em toda e qualquer coluna que contém um 1 *pivotal*, todas as outras entradas são iguais a zero.
- Toda linha contendo apenas zeros está no fim da matriz.

À partir dessa definição, é possível mostrar que para qualquer matriz A , existe uma matriz \tilde{A} na forma escalonada reduzida por linhas que pode ser obtida à partir de operações elementares nas linhas de A . Além disso, é possível mostrar também que \tilde{A} é única. Ao algoritmo utilizado para encontrar \tilde{A} é dado o nome de **Algoritmo de Eliminação de Gauss-Jordan**.

ALGORITMO DE ELIMINAÇÃO DE GAUSS-JORDAN

Para levar uma matriz A a sua forma escalonada reduzida por linhas \tilde{A} devemos seguir os seguintes passos:

1. Encontre a primeira coluna que não é composta apenas de zeros, chame isso de primeira coluna pivotal e chame sua primeira entrada diferente de zero de pivô. Se o pivô não for na primeira linha, mova a linha que a contém para o topo da matriz.
2. Divida a primeira linha inteira pelo pivô, de modo que a primeira entrada da primeira coluna pivotal seja igual a 1.
3. Adicione múltiplos apropriados da primeira linha às outras linhas para garantir que todas as outras entradas da primeira coluna pivotal sejam iguais a 0. O 1 na primeira coluna é agora um pivô 1.

- Escolha a próxima coluna que contém pelo menos uma entrada diferente de zero abaixo da primeira linha e coloque a linha que contém o novo pivô na posição da segunda linha. Faça do pivô um pivô 1: divida a linha inteira pelo pivô e adicione múltiplos apropriados desta linha às outras linhas abaixo, para tornar todas as outras entradas desta coluna iguais a 0.

- Repita o processo até que a matriz esteja em sua forma escalonada reduzida por linhas.

Assuma o caso em que a matriz de coeficiente A e o vetor de constantes b são tais que a matriz ampliada é dada por:

$$\left[\begin{array}{ccc|c} 2 & 2 & 1 & 1 \\ 1 & 3 & 1 & 2 \\ 1 & 2 & 2 & -1 \end{array} \right]$$

- Passo 1: Defina a matriz M

```
M = np.array([(2, 2, 1, 1),
              (1, 3, 1, 2),
              (1, 2, 2, -1)], dtype=float)
print('Matriz ampliada =\n', M)
```

```
Matriz ampliada =
[[ 2.  2.  1.  1.]
 [ 1.  3.  1.  2.]
 [ 1.  2.  2. -1.]]
```

- Passo 2: Divida a linha 1 pelo primeiro elemento da primeira linha

```
M[0,:] = M[0,:] / M[0,0]
print(M)
```

```
[[ 1.  1.  0.5  0.5]
 [ 1.  3.  1.  2. ]
 [ 1.  2.  2. -1. ]]
```

- Passo 3: Subtraia a linha 1 da linha 2 e da linha 3

```
M[1,:] = M[1,:] - M[0,:]
M[2,:] = M[2,:] - M[0,:]
print(M)
```

```
[[ 1.  1.  0.5  0.5]
 [ 0.  2.  0.5  1.5]
 [ 0.  1.  1.5 -1.5]]
```

- Passo 4: Divida a linha 2 pelo segundo elemento da segunda linha

```
M[1,:] = M[1,:] / M[1,1]

print(M)
```

```
[[ 1.  1.  0.5  0.5 ]
 [ 0.  1.  0.25 0.75]
 [ 0.  1.  1.5 -1.5 ]]
```

- Passo 5: Subtraia a linha 2 da linha 3

```
M[2,:] = M[2,:] - M[1,:]

print(M)
```

```
[[ 1.  1.  0.5  0.5 ]
 [ 0.  1.  0.25 0.75]
 [ 0.  0.  1.25 -2.25]]
```

- Passo 6: Divida a linha 3 pelo terceiro elemento da terceira linha

```
M[2,:] = M[2,:] / M[2,2]

print(M)
```

```
[[ 1.  1.  0.5  0.5 ]
 [ 0.  1.  0.25 0.75]
 [ 0.  0.  1.  -1.8 ]]
```

- Passo 7: Multiplique a linha 3 pelo terceiro elemento da segunda linha e subtraia da linha 2

```
M[1,:] = M[1,:] - M[1,2] * M[2,:]

print(M)
```

```
[[ 1.  1.  0.5  0.5]
 [ 0.  1.  0.  1.2]
 [ 0.  0.  1. -1.8]]
```

- Passo 8: Multiplique a linha 3 pelo terceiro elemento da primeira linha e subtraia da linha 1

```
M[0,:] = M[0,:] - M[0,2] * M[2,:]
print(M)
```

```
[[ 1.  1.  0.  1.4]
 [ 0.  1.  0.  1.2]
 [ 0.  0.  1. -1.8]]
```

- Passo 9: Subtraia a linha 2 da linha 1

```
M[0,:] = M[0,:] - M[1,:]
print(M)
```

```
[[ 1.  0.  0.  0.2]
 [ 0.  1.  0.  1.2]
 [ 0.  0.  1. -1.8]]
```

Temos a nossa matriz em sua forma escalonada reduzida por linhas! A solução do sistema é tal que:

```
print('A solução de x1 é: {:.2f}'.format(M[0,3]))
print('A solução de x2 é: {:.2f}'.format(M[1,3]))
print('A solução de x3 é: {:.2f}'.format(M[2,3]))
```

```
A solução de x1 é: 0.20
A solução de x2 é: 1.20
A solução de x3 é: -1.80
```

Uma forma mais simples de chegar na forma escalonada reduzida por linhas é através do pacote SymPy e das funções `Matrix` e `rref`:


```
import sympy

M_sympy = sympy.Matrix([(2, 2, 1, 1),
                        (1, 3, 1, 2),
                        (1, 2, 2, -1)])

M_sympy.rref()[0]
```

$$\begin{bmatrix} 1 & 0 & 0 & \frac{1}{5} \\ 0 & 1 & 0 & \frac{1}{5} \\ 0 & 0 & 1 & -\frac{9}{5} \end{bmatrix}$$

7.4.2 Solução de sistemas exatamente identificados

Uma outra forma de resolver sistemas de equações exatamente identificados, quando o número de incógnitas é igual ao número de equações (i.e., matriz A é quadrada) é através da matriz inversa de A . Para o caso em que A^{-1} existe, o sistema é tal que

$$\vec{x} = A^{-1} \cdot \vec{b}$$

Para que seja possível fazer dessa forma, A deve ser uma matriz quadrada e seu determinante ser diferente de 0. Mais uma vez assumo o caso em que A e \vec{b} são dados por:

$$A = \begin{bmatrix} 2 & 2 & 1 \\ 1 & 3 & 1 \\ 1 & 2 & 2 \end{bmatrix} \quad \vec{b} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}$$

O primeiro passo é conferir se a matrix A é quadrada. Podemos fazer isso usando a função `numpy.shape()`

```
b = np.array([1, 2, -1])
A = np.array([(2, 2, 1), (1, 3, 1), (1, 2, 2)])

np.shape(A)[0] == np.shape(A)[1]
```

True

O próximo passo é ver se o determinante da matriz é igual a 0 e para isso usamos um função do subpacote de álgebra linera do numpy, `numpy.linalg.det()`:

```
print('A =')
print(A)

print('\nDeterminante = ', np.round(np.linalg.det(A)))
```

```
A =
[[2 2 1]
 [1 3 1]
 [1 2 2]]
```

```
Determinante = 5.0
```

Como ambas as condições são satisfeitas, por fim basta calcular a inversa da matriz A com `numpy.linalg.inv()` e multiplicar por \vec{b} para chegar nos valores de x , y e z que solucionam o sistema de equações.

```
print('A =')
print(A)

print("\nInversa de A = ")
print(np.linalg.inv(A))
```

```
A =
[[2 2 1]
 [1 3 1]
 [1 2 2]]
```

```
Inversa de A =
[[ 0.8 -0.4 -0.2]
 [-0.2  0.6 -0.2]
 [-0.2 -0.4  0.8]]
```

```
solution = np.linalg.inv(A) @ b
solution
```

```
array([ 0.2,  1.2, -1.8])
```

```
print('A solução de x1 é: {:.2f}'.format(solution[0]))
print('A solução de x2 é: {:.2f}'.format(solution[1]))
print('A solução de x3 é: {:.2f}'.format(solution[2]))
```

A solução de x1 é: 0.20
A solução de x2 é: 1.20
A solução de x3 é: -1.80

Uma última alternativa para resolver o sistema $A \cdot \vec{x} = \vec{b}$, é utilizar a função `solve` do subpacote de álgebra linear do NumPy. Essa função faz o processo de resolução do sistema de forma direta e nos cospe o vetor de resultado.

```
np.linalg.solve(A,b)
```

```
array([ 0.2,  1.2, -1.8])
```

8 Gestão e análise de dados

Uma das principais aplicações para o Python bla bla bla

8.1 O que é o NumPy?

NumPy (**N**umerical **P**ython) é o pacote fundamental

9 Visualização

Uma das principais aplicações para o Python bla bla bla

9.1 O que é o NumPy?

NumPy (**N**umerical **P**ython) é o pacote fundamental

10 Análise empírica integrada

Uma das principais aplicações para o Python bla bla bla

10.1 O que é o NumPy?

NumPy (**N**umerical **P**ython) é o pacote fundamental

Parte III

Temas complementares

11 Introdução à programação orientada a objetos (OOP)

In summary, this book has no content whatsoever.

12 Introdução ao R

In summary, this book has no content whatsoever.

References